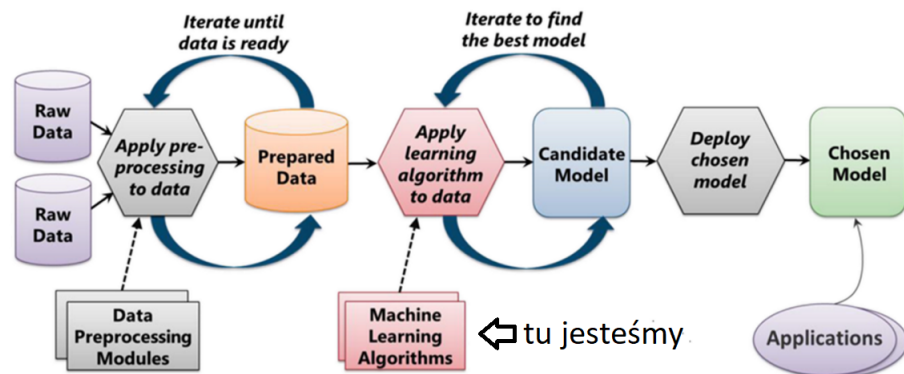


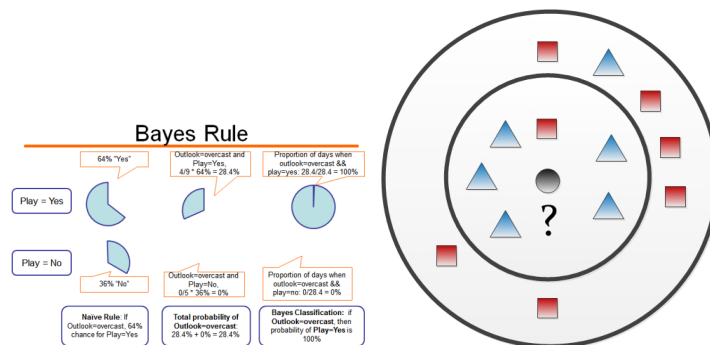
Ćwiczenie - 5 Sztuczna Inteligencja

Budowanie modeli klasyfikacji: k-NN oraz Naiwny klasyfikator Bayesa

The Machine Learning Process



From "Introduction to Microsoft Azure" by David Chappell



Krótkie wprowadzenie (Short introduction)

W ćwiczeniu wprowadzamy kolejne dwa modele klasyfikacji, techniki modelowania procesu decyzyjnego (in the task we have two more classifiers to implement) - metodę $k-NN$ (k Nearest Neighbours) oraz Naiwny Klasyfikator Bayesa (Naive Bayes classifier). Przejdźmy do opisu zadania i wprowadzenia teoretycznego z przykładami. (Let us to show theory and toy examples of both algorithms)

Zadania do wykonania (Set of tasks to do)


1) Tworzymy na pulpicie katalog w formacie Imię_nazwisko, w którym umieszczamy wszystkie pliki związane z ćwiczeniem (Create the folder to collect your all files),

- 2) Czytamy teorię związaną z klasyfikacją metodą k najbliższych sąsiadów ($k-NN$), oraz Naiwnym Klasyfikatorem Bayesa, w razie problemów ze zrozumieniem, analizujemy przykłady na kartce. (Read the theory about $k-NN$ and Naive Bayes classifier, in case of problems resolve simple examples on the piece of paper),
- 3) Generujemy system treningowy (australian_TRN.txt) oraz testowy (australian_TST.txt) za pomocą programu data_splitter.exe. (Generate test and training decision systems using data_splitter.exe program)
- 4) Otrzymany system testowy klasyfikujemy systemem treningowym metodą $2-NN$, za pośrednictwem programu napisanego w dowolnym języku programowania. Implementujemy algorytm dla: Metryki Euklidesa, Canberra, Czebyszewa, Manhattan oraz dla Bezwzględego współczynnika korelacji Pearsona. (Classify your tst system based on trn system with use of $k-NN$ classifier - prepare implementation in chosen programming language)
- 5) Implementujemy w dowolnym języku programowania (preferowany C++) klasyfikator Bayesa. Wynikiem działania programu powinny być dwa pliki:
 - a) dec_bayes.txt - zawierający podjęte decyzje dla obiektów systemu australian_TST.txt na podstawie obiektów systemu australian_TRN.txt
 - b) acc_bayes.txt - zawierający dwie wartości: Accuracy Globalne klasyfikacji i Accuracy Zbalansowane klasyfikacji.
 (Classify your tst system based on trn system with use of Naive Bayes classifier - prepare implementation in chosen programming language)
- 6) W przypadku programowania w C++, ułatwieniem może być użycie programu demonstracyjny znajdujący się na stronie <http://wmii.uwm.edu.pl/~artem> w zakładce Dydaktyka/Sztuczna Inteligencja (Its the link to exemplary auxiliary program).

Klasyfikator $k-NN$ - część teoretyczna

Przyjmując, że nie znamy figury w centrum Rys. 1 możemy przeprowadzać dedukcję na podstawie obserwacji figur stojących w jej sąsiedztwie prowadzącą do jej zdefiniowania. Przykładowo, gdy rozważamy po dwie najbliższe figury spośród trójkątów i kwadratów, widzimy, że sumaryczna odległość dwóch trójkątów od figury nieznannej jest mniejsza niż odległość pary kwadratów, stąd możemy przypuszczać, że naszą ukrytą figurą jest trójkąt. Tego typu sposób klasyfikacji nazywamy metodą k najbliższych sąsiadów, w naszym przykładzie rozważaliśmy $k=2$ w sensie wyboru po dwa obiekty z każdej dostępnej klasy obiektów.

- Dla danego systemu testowy (X, A, c) i treningowego (Y, A, c) , gdzie X, Y to odpowiednio uniwersum obiektów testowych i treningowych, $A = (a_1, a_2, \dots, a_n)$ jest zbiorem atrybutów warunkowych, $c \in D = \{c_1, c_2, \dots, c_m\}$ jest atrybutem decyzyjnym.



Rysunek 1: Wizualizacja problemu klasyfikacji metodą k najbliższych sąsiadów

Dla obiektów $x \in X, y \in Y$ postaci,

$$x = a_1(x) \ a_2(x) \ \dots \ a_n(x) \ c(x)$$

$$y = a_1(y) \ a_2(y) \ \dots \ a_n(y) \ c(y)$$

zdefiniujemy podstawowe metryki,

Metryka Manhattan przedstawia się następująco,

$$d(x, y) = \sum_{i=1}^n |a_i(x) - a_i(y)|$$

Metryka Euklidesowa szczególnym przypadkiem metryki Minkowskiego,

$$d(x, y) = \sqrt{(a_1(x) - a_1(y))^2 + (a_2(x) - a_2(y))^2 + \dots + (a_n(x) - a_n(y))^2}$$

czyli zapisując ogólnie:

$$d(x, y) = \sqrt{\sum_{i=1}^n (a_i(x) - a_i(y))^2}$$

Metryka Canberra jest postaci,

$$d(x, y) = \sum_{i=1}^n \left| \frac{a_i(x) - a_i(y)}{a_i(x) + a_i(y)} \right|$$

Metryka Czebyszewa określana jest wzorem,

$$d(x, y) = \max(|a_i(x) - a_i(y)|), \text{ dla } i = 1, 2, \dots, n$$

Bezwzględny współczynnik korelacji Pearsona może być używany w poniższy sposób,

$$d(x, y) = 1 - |r_{x,y}|$$

$$r_{x,y} = \frac{1}{n} * \sum_{i=1}^n \left(\frac{a_i(x) - \bar{x}}{\sqrt{\frac{1}{n} \sum_{i=1}^n (a_i(x) - \bar{x})^2}} \right) \left(\frac{a_i(y) - \bar{y}}{\sqrt{\frac{1}{n} \sum_{i=1}^n (a_i(y) - \bar{y})^2}} \right)$$

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n a_i(x), \bar{y} = \frac{1}{n} \sum_{i=1}^n a_i(y)$$

Procedura algorytmu k-NN z równym uwzględnianiem klas decyzyjnych

- Wczytujemy system testowy (X, A, c) i treningowy (Y, A, c) , gdzie X, Y to odpowiednio uniwersum obiektów testowych i treningowych, $A = (a_1, a_2, \dots, a_n)$ jest zbiorem atrybutów warunkowych, $c \in D = \{c_1, c_2, \dots, c_m\}$ jest atrybutem decyzyjnym.
- Ustalamy metrykę d liczenia odległości między obiektami, oraz liczbę najbliższych sąsiadów decydujących o klasyfikacji k ,
- Klasyfikujemy wszystkie obiekty testowe za pomocą k najbliższych obiektów, każdej z klas systemu treningowego, (decyzję przekazuje klasa, której obiekty są najbliższe testowego w sensie metryki d),
- Po zakończeniu klasyfikacji, tworzymy Macierz Predykcji, zawierającą informacje o jakości klasyfikacji systemu testowego X :

Parametry mówiące o jakości przeprowadzonej klasyfikacji, które należy umieścić w raporcie klasyfikacji (w Macierzy Predykcji) są definiowane następująco:

Dla $\Lambda_{c \in D}$

$$acc_c = \frac{\text{liczba obiektów poprawnie sklasyfikowanych w klasie decyzyjnej } c}{\text{liczba obiektów chwyconych w klasie } c}$$

$$cov_c = \frac{\text{liczba obiektów chwyconych w klasie } c}{\text{liczba obiektów klasy } c}$$

$$TPR_c = \frac{x}{x + \text{liczba obiektów z pozostałych klas błędnie trafiających do klasy } c}$$

przyjmujemy, że $x = \text{liczba obiektów poprawnie sklasyfikowanych w klasie decyzyjnym } c$

Ostatecznie wyliczamy wartości globalne, które umieszczamy pod Macierzą Predykcji,

$$acc_{global} = \frac{\text{ilość obiektów poprawnie sklasyfikowanych w całym systemie TST}}{\text{ilość obiektów chwyconych w systemie TST}}$$

$$cov_{global} = \frac{\text{ilość obiektów chwyconych w całym systemie TST}}{\text{ilość obiektów systemu TST}}$$

Przykładowa klasyfikacja 2-NN Wczytujemy system testowy postaci,

Tabela 1: System Testowy (X, A, c)

| | a_1 | a_2 | a_3 | a_4 | c |
|-------|-------|-------|-------|-------|-----|
| x_1 | 2 | 4 | 2 | 1 | 4 |
| x_2 | 1 | 2 | 1 | 1 | 2 |
| x_3 | 9 | 7 | 10 | 7 | 4 |
| x_4 | 4 | 4 | 10 | 10 | 2 |

oraz system treningowy

Tabela 2: System Treningowy (Y, A, c)

| | a_1 | a_2 | a_3 | a_4 | c |
|-------|-------|-------|-------|-------|-----|
| y_1 | 1 | 3 | 1 | 1 | 2 |
| y_2 | 10 | 3 | 2 | 1 | 2 |
| y_3 | 2 | 3 | 1 | 1 | 2 |
| y_4 | 10 | 9 | 7 | 1 | 4 |
| y_5 | 3 | 5 | 2 | 2 | 4 |
| y_6 | 2 | 3 | 1 | 1 | 4 |

Ustalmy $k=2$ i d jako metrykę Euklidesa

Metryka Euklidesa działa następująco, dla obiektów

$$x = a_1(x) \ a_2(x) \dots a_n(x) \ c(x)$$

$$y = a_1(y) \ a_2(y) \dots a_n(y) \ c(y)$$

$$d(x, y) = \sqrt{(a_1(x) - a_1(y))^2 + (a_2(x) - a_2(y))^2 + \dots + (a_n(x) - a_n(y))^2}$$

czyli zapisując ogólnie:

$$d(x, y) = \sqrt{\sum_{i=1}^n (a_i(x) - a_i(y))^2}$$

Przechodzimy do klasyfikacji obiektów testowych:

Dla x_1 2 4 2 1 4

$$d(x_1, y_1) = \sqrt{(2-1)^2 + (4-3)^2 + (2-1)^2 + (1-1)^2} = \sqrt{3}$$

$$d(x_1, y_2) = \sqrt{65}$$

$$d(x_1, y_3) = \sqrt{2}$$

$$d(x_1, y_4) = \sqrt{114}$$

$$d(x_1, y_5) = \sqrt{3}$$

$$d(x_1, y_6) = \sqrt{2}$$

Dwóch najbliższych sąsiadów obiektu testowego x_1 w klasie decyzyjnej 2 to y_3, y_1

Klasa 2 głosuje z mocą $\sqrt{2} + \sqrt{3}$

Najbliższymi sąsiadami x_1 w klasie decyzyjnej 4 są y_6, y_5

Klasa 4 głosuje z mocą $\sqrt{2} + \sqrt{3}$

$$\sqrt{2} + \sqrt{3} = \sqrt{2} + \sqrt{3}$$

Stąd obiekt x_1 nie jest chwytyany, nie jesteśmy w stanie powiedzieć, która klasa jest bliżej w sensie dwóch najbliższych sąsiadów.

Dla x_2 1 2 1 1 2

$$d(x_2, y_1) = 1$$

$$d(x_2, y_2) = \sqrt{84}$$

$$d(x_2, y_3) = \sqrt{2}$$

$$d(x_2, y_4) = \sqrt{166}$$

$$d(x_2, y_5) = \sqrt{15}$$

$$d(x_2, y_6) = \sqrt{2}$$

Klasa 2 głosuje z mocą $1 + \sqrt{2}$

Klasa 4 głosuje z mocą $\sqrt{2} + \sqrt{15}$

$$1 + \sqrt{2} < \sqrt{2} + \sqrt{15}$$

Obiekt x_2 otrzymuje decyzję 2, jest poprawnie sklasyfikowany.

Dla x_3 9 7 10 7 4

$$d(x_3, y_1) = \sqrt{197}$$

$$d(x_3, y_2) = \sqrt{117}$$

$$d(x_3, y_3) = \sqrt{182}$$

$$d(x_3, y_4) = \sqrt{50}$$

$$d(x_3, y_5) = \sqrt{129}$$

$$d(x_3, y_6) = \sqrt{182}$$

Klasa 2 głosuje z mocą $\sqrt{117} + \sqrt{182}$

Klasa 4 głosuje z mocą $\sqrt{50} + \sqrt{129}$

$$\sqrt{50} + \sqrt{129} < \sqrt{117} + \sqrt{182}$$

Obiekt x_3 otrzymuje decyzję 4, jest poprawnie sklasyfikowany.

Dla x_4 4 4 10 10 2

$$d(x_4, y_1) = \sqrt{172}$$

$$d(x_4, y_2) = \sqrt{182}$$

$$d(x_4, y_3) = \sqrt{167}$$

$$d(x_4, y_4) = \sqrt{151}$$

$$d(x_4, y_5) = \sqrt{130}$$

$$d(x_4, y_6) = \sqrt{167}$$

Klasa 2 głosuje z mocą $\sqrt{167} + \sqrt{172}$

Klasa 4 głosuje z mocą $\sqrt{130} + \sqrt{151}$
 $\sqrt{130} + \sqrt{151} < \sqrt{167} + \sqrt{172}$

Obiekt x_4 otrzymuje decyzję 4, jest błędnie sklasyfikowany.

Podsumowując klasyfikację:

Obiekt x_1 nie jest chwytny

Obiekt x_2 otrzymuje decyzję 2, jest poprawnie sklasyfikowany

Obiekt x_3 otrzymuje decyzję 4, jest poprawnie sklasyfikowany

Obiekt x_4 otrzymuje decyzję 4, jest błędnie sklasyfikowany.

Macierz Predykcji, stanowiąca raport z klasyfikacji możemy zobaczyć w Tab. 3.

Tabela 3: Macierz Predykcji

| | 2 | 4 | <i>No. of obj.</i> | <i>Accuracy</i> | <i>Coverage</i> |
|---------------------------|-----|-----|--------------------|-----------------|-----------------|
| 2 | 1 | 1 | 2 | 0.5 | 1.0 |
| 4 | 0 | 1 | 2 | 1.0 | 0.5 |
| <i>True Positive Rate</i> | 1.0 | 0.5 | | | |

Naiwny Klasyfikator Bayesa - część teoretyczna

Klasyfikator z rodziny metod probabilistycznych. Wymaga założenia, że atrybuty systemu decyzyjnego są niezależne od siebie, takie założenie często jest niezgodne z sytuacją rzeczywistą, stąd klasyfikator nazywamy naiwnym. Pomimo opisanego założenia klasyfikator działa w wielu przypadkach zaskakująco dobrze. Istnieje teoria, że tego typu klasyfikację może kierować się nasz umysł - patrz artykuł:

<http://reverendbayes.wordpress.com/2008/05/29/bayesian-theory-in-new-scientist/>.

Założmy, że mamy dane systemy decyzyjne: treningowy (U_{trn}, A, d) oraz testowy (U_{tst}, A, d) , gdzie U jest zbiorem obiektów, $A = \{a_1, a_2, \dots, a_n\}$ zbiorem atrybutów warunkowych, $d \in D = \{d_1, d_2, \dots, d_k\}$ atrybutem decyzyjnym.

Klasyfikacja obiektu testowego $v \in U_{tst}$ opisanego jako $a_1(v), a_2(v), \dots, a_n(v)$ polega na obliczeniu dla każdej z klas decyzyjnych parametru:

$$P(d = d_i | b_1 = a_1(v), b_2 = a_2(v), \dots, b_n = a_n(v))$$

gdzie w postaci Twierdzenia Bayesa mamy,

$$\frac{P(b_1 = a_1(v), b_2 = a_2(v), \dots, b_n = a_n(v) | d = d_i) * P(d = d_i)}{P(b_1 = a_1(v), b_2 = a_2(v), \dots, b_n = a_n(v))}$$

Mianownik możemy pominąć ponieważ jest stały dla wszystkich klas decyzyjnych. Przy założeniu że atrybuty są niezależne licznik możemy obliczyć jako

$$P(b_1 = a_1(v), b_2 = a_2(v), \dots, b_n = a_n(v) | d = d_i) * P(d = d_i) = P(d = d_i) * \prod_{m=1}^n P(b_m = a_m(v) | d = d_i)$$

W praktyce możemy zastosować oszacowanie częściowe,

$$P(b_m = a_m(v)|d = d_i) = \frac{\text{liczba wystąpień wartości } b_m = a_m(v) \text{ w klasie } d_i}{\text{liczność klasy treningowej } d_i}$$

Każda klasa głosuje wartością parametru:

$$Param_{d=d_i} = P(d = d_i) * \prod_{m=1}^n P(b_m = a_m(v)|d = d_i)$$

W tym wariancie, w przypadku gdy dla klasy d_i uzyskamy wartość $P(b_m = a_m(v)|d = d_i) = 0$, wyszukujemy w pozostałych klasach najmniejszej niezerowej wartości $P(b_m = a_m(v)|d = d_j)$ i przypisujemy ją do $P(b_m = a_m(v)|d = d_i)$ po odpowiednim zmniejszeniu (np dzieląc przez 2). Jeżeli klas z zerowym wystąpieniem $b_m = a_m(v)$ jest więcej, każdej z nich przypisujemy tę zmniejszoną wartość. Innym sposobem na radzenie sobie z problemem zerowych wartości $P(b_m = a_m(v)|d = d_i)$ jest faworyzowanie pozostałych klas zawierających wartość $b_m = a_m(v)$, następuje zwiększanie liczników o jeden podczas obliczania prawdopodobieństwa. W przypadku gdy żadna z klas nie zawiera wartości $b_m = a_m(v)$, prawdopodobieństwa zerowe są pomijane w iloczynie.

Aby zapobiec problemowi małych bliskich zeru liczb, możemy poszczególne prawdopodobieństwa logarytmować. W praktycznym zastosowaniu, dopuszcza się użycie sumy prawdopodobieństw, (ponieważ mnożenie przez małe wartości może doprowadzić do zmniejszenia parametru klasy do zera, przy ograniczonej dokładności) w naszym wariancie algorytmu każda klasa decyzyjna będzie głosowała za pomocą parametru:

$$Param_{d=d_i} = P(d = d_i) * \sum_{m=1}^n P(b_m = a_m(v)|d = d_i)$$

W przypadku problemu z zerową licznością deskryptora $b_m = a_m(v)$, stosujemy faworyzowanie klas, podobnie jak w wariancie z iloczynem prawdopodobieństw.

Gdy podczas klasyfikacji parametry klas są jednakowe, konflikt rozwiązujemy nadając obiektowi testowemu losową decyzję.

W przypadku gdy atrybuty są ciągłe, oraz zakładając że mają rozkład normalny, poszczególne prawdopodobieństwa $P(b_m = a_m(v)|d = d_i)$ szacujemy za pomocą funkcji Gaussa.

$$f(x) = \frac{1}{\sqrt{(2 * \pi * \sigma_c^2)}} * e^{\frac{-(x-\mu_c)^2}{2 * \sigma_c^2}}$$

Do jej obliczenia potrzebujemy średnie z klas oraz wariancje wartości w klasach.

$$\mu_c = \frac{\sum_{i=1}^{licznosc\ klasy\ c} a(v_i)}{licznosc\ klasy\ c}$$

$$\sigma_c^2 = \frac{1}{licznosc\ klasy\ c} * \sum_{i=1}^{licznosc\ klasy\ c} (a(v_i) - \mu_c)^2$$

Przykład działania Naiwnego Klasyfikatora Bayesa

Wczytujemy system testowy (problemy do rozwiązania z ukrytymi decyzjami eksperta) postaci,

Tabela 4: System Testowy (X, A, c)

| | a_1 | a_2 | a_3 | a_4 | c |
|-------|-------|-------|-------|-------|-----|
| x_1 | 2 | 4 | 2 | 1 | 4 |
| x_2 | 1 | 2 | 1 | 1 | 2 |
| x_3 | 9 | 7 | 10 | 7 | 4 |
| x_4 | 4 | 4 | 10 | 10 | 2 |

oraz system treningowy (bazę wiedzy służącą do rozwiązywania problemów)

Widzimy, że $P(c = 2) = \frac{3}{6} = \frac{1}{2}$, $P(c = 4) = \frac{1}{2}$.

Rozpoczynamy od klasyfikacji obiektu testowego

x_1 2 4 2 1 4

Wyliczamy $Param_{c=2} = P(c = 2) * \sum_{i=1}^4 P(a_i = v_i|c = 2)$,

$$P(a_1 = 2|c = 2) = \frac{1}{3}$$

$P(a_2 = 4|c = 2) = \frac{1}{3}$ nie da się obsłużyć tej wartości, żadna z klas nie zawiera $a_2 = 4$

$$P(a_3 = 2|c = 2) = \frac{1}{3}$$

$$P(a_4 = 1|c = 2) = \frac{1}{3}$$

Tabela 5: System Treningowy (Y, A, c)

| | a_1 | a_2 | a_3 | a_4 | c |
|-------|-------|-------|-------|-------|-----|
| y_1 | 1 | 3 | 1 | 1 | 2 |
| y_2 | 10 | 3 | 2 | 1 | 2 |
| y_3 | 2 | 3 | 1 | 1 | 2 |
| y_4 | 10 | 9 | 7 | 1 | 4 |
| y_5 | 3 | 5 | 2 | 2 | 4 |
| y_6 | 2 | 3 | 1 | 1 | 4 |

Ostatecznie $Param_{c=2} = \frac{1}{2} * (\frac{1}{3} + \frac{0}{3} + \frac{1}{3} + \frac{3}{3}) = \frac{5}{6}$;

oraz $Param_{c=4} = P(c = 4) * \sum_{i=1}^4 P(a_i = v_i | c = 4)$,

$$P(a_1 = 2 | c = 4) = \frac{1}{3}$$

$P(a_2 = 4 | c = 4) = \frac{0}{3}$ nie da się obsłużyć tej wartości, żadna z klas nie zawiera $a_2 = 4$

$$P(a_3 = 2 | c = 4) = \frac{1}{3}$$

$$P(a_4 = 1 | c = 4) = \frac{3}{3}$$

Ostatecznie $Param_{c=4} = \frac{1}{2} * (\frac{1}{3} + \frac{0}{3} + \frac{1}{3} + \frac{2}{3}) = \frac{2}{3}$;

$Param_{c=2} > Param_{c=4}$, obiekt x_1 dostaje decyzję 2, ta decyzja nie jest zgodna z ukrytą decyzją eksperta stąd obiekt jest błędnie sklasyfikowany,

Podczas klasyfikacji pierwszego obiektu napotykamy licznosc zero dla $a_2 = 4$, której nie możemy obsłużyć, ponieważ żadna z istniejących klas nie zawiera wartości $a_2 = 4$.

Przejdźmy do klasyfikacji obiektu testowego

x_2 1 2 1 1 4

Wyliczamy $Param_{c=2} = P(c = 2) * \sum_{i=1}^4 P(a_i = v_i | c = 2)$,

$P(a_1 = 1 | c = 2) = \frac{1}{3}$ zwiększamy licznik o 1, ponieważ $P(a_1 | c = 4) = 0$, $P(a_1 = 1 | c = 2) = \frac{2}{3}$

$P(a_2 = 2 | c = 2) = \frac{0}{3}$ nie da się obsłużyć tej wartości, żadna z klas nie zawiera $a_2 = 2$

$$P(a_3 = 1 | c = 2) = \frac{1}{3}$$

$$P(a_4 = 1 | c = 2) = \frac{3}{3}$$

Ostatecznie $Param_{c=2} = \frac{1}{2} * (\frac{2}{3} + \frac{0}{3} + \frac{1}{3} + \frac{3}{3}) = 1$;

oraz $Param_{c=4} = P(c = 4) * \sum_{i=1}^4 P(a_i = v_i | c = 4)$,

$P(a_1 = 1 | c = 4) = \frac{0}{3}$ w tej sytuacji zwiększam o 1 licznik $P(a_1 = 1 | c = 2)$, faworyzując klasy zawierające przynajmniej jedną wartość $a_1 = 1$

$P(a_2 = 2 | c = 4) = \frac{0}{3}$ nie da się obsłużyć tej wartości, żadna z klas nie zawiera $a_2 = 2$

$$P(a_3 = 1 | c = 4) = \frac{1}{3}$$

$$P(a_4 = 1 | c = 4) = \frac{2}{3}$$

Ostatecznie $Param_{c=2} = \frac{1}{2} * (\frac{0}{3} + \frac{0}{3} + \frac{1}{3} + \frac{2}{3}) = \frac{1}{2}$;

$Param_{c=2} > Param_{c=4}$, obiekt x_2 dostaje decyzję 2, ta decyzja jest zgodna z ukrytą decyzją eksperta stąd obiekt jest poprawnie sklasyfikowany,

Przejdźmy do klasyfikacji obiektu testowego

x_3 9 7 10 7 4

Wyliczamy $Param_{c=2} = P(c=2) * \sum_{i=1}^4 P(a_i = v_i | c=2)$,

$P(a_1 = 9 | c=2) = \frac{0}{3}$ nie da się obsłużyć tej wartości

$P(a_2 = 7 | c=2) = \frac{0}{3}$ nie da się obsłużyć tej wartości

$P(a_3 = 10 | c=2) = \frac{0}{3}$ nie da się obsłużyć tej wartości

$P(a_4 = 7 | c=2) = \frac{0}{3}$ nie da się obsłużyć tej wartości

Ostatecznie $Param_{c=2} = \frac{1}{2} * (\frac{0}{3} + \frac{0}{3} + \frac{0}{3} + \frac{0}{3}) = 0$;

oraz $Param_{c=4} = P(c=4) * \sum_{i=1}^4 P(a_i = v_i | c=4)$,

$P(a_1 = 9 | c=4) = \frac{0}{3}$ nie da się obsłużyć tej wartości

$P(a_2 = 7 | c=4) = \frac{0}{3}$ nie da się obsłużyć tej wartości

$P(a_3 = 10 | c=4) = \frac{0}{3}$ nie da się obsłużyć tej wartości

$P(a_4 = 7 | c=4) = \frac{0}{3}$ nie da się obsłużyć tej wartości

Ostatecznie $Param_{c=2} = \frac{1}{2} * (\frac{0}{3} + \frac{0}{3} + \frac{0}{3} + \frac{0}{3}) = 0$;

$Param_{c=2} == Param_{c=4}$, obiekt x_3 dostaje decyzję losową $los(2, 4) = 4$, ta decyzja jest zgodna z ukrytą decyzją eksperta stąd obiekt jest poprawnie sklasyfikowany,

Przejdźmy do klasyfikacji obiektu testowego

x_4 4 4 10 10 4

Wyliczamy $Param_{c=2} = P(c=2) * \sum_{i=1}^4 P(a_i = v_i | c=2)$,

$P(a_1 = 4 | c=2) = \frac{0}{3}$ nie da się obsłużyć tej wartości

$P(a_2 = 4 | c=2) = \frac{0}{3}$ nie da się obsłużyć tej wartości

$P(a_3 = 10 | c=2) = \frac{0}{3}$ nie da się obsłużyć tej wartości

$P(a_4 = 10 | c=2) = \frac{0}{3}$ nie da się obsłużyć tej wartości

Ostatecznie $Param_{c=2} = \frac{1}{2} * (\frac{0}{3} + \frac{0}{3} + \frac{0}{3} + \frac{0}{3}) = 0$;

oraz $Param_{c=4} = P(c=4) * \sum_{i=1}^4 P(a_i = v_i | c=4)$,

$P(a_1 = 4 | c=4) = \frac{0}{3}$ nie da się obsłużyć tej wartości

$P(a_2 = 4 | c=4) = \frac{0}{3}$ nie da się obsłużyć tej wartości

$P(a_3 = 10 | c=4) = \frac{0}{3}$ nie da się obsłużyć tej wartości

$P(a_4 = 10 | c=4) = \frac{0}{3}$ nie da się obsłużyć tej wartości

Ostatecznie $Param_{c=2} = \frac{1}{2} * (\frac{0}{3} + \frac{0}{3} + \frac{0}{3} + \frac{0}{3}) = 0$;

$Param_{c=2} == Param_{c=4}$, obiekt x_4 dostaje decyzję losową $los(2, 4) = 4$, ta decyzja nie jest zgodna z ukrytą decyzją eksperta stąd obiekt jest poprawnie sklasyfikowany,

Ostatecznie wyliczamy parametry:

$$Global_Accuracy = \frac{\text{liczba obiektów tst poprawnie sklasyfikowanych w całym systemie}}{\text{liczba obiektów sklasyfikowanych w całym systemie}}$$

$$Balanced_Accuracy = \frac{\sum_{i=1}^{\text{liczba klas}} \frac{\text{liczba obiektów tst poprawnie sklasyfikowanych w klasie } c_i}{\text{liczba obiektów sklasyfikowanych w klasie } c_i}}{\text{liczba klas}}$$

$$Global_Accuracy = \frac{2}{4} = \frac{1}{2}$$

$$Balanced_Accuracy = \frac{\frac{1}{2} + \frac{1}{2}}{2} = \frac{1}{2}$$

| Obiekt tst | Ukryta decyzja eksperta | Decyzja naszego klasyfikatora |
|------------|-------------------------|-------------------------------|
| x_1 | 4 | 2 |
| x_2 | 2 | 2 |
| x_3 | 4 | 4 |
| x_4 | 2 | 4 |

the source of image from the first page: <http://www.simafore.com/>